

第11章 概率图模型

11.1 模型表示

带阴影的节点表示可观测的变量。

不带阴影的节点表示隐变量。



11.1.1 有向图模型 (贝叶斯网络)

11.1.2 无向图模型

Sigmoid 神经网络

11.1.3 朴素贝叶斯分类器


$$p(y|x, \theta) \propto p(y|\theta_c) \prod_{i=1}^d p(x_i|y, \theta_{iy})$$



朴素贝叶斯

Logistic 回归。

11.2.3 HMM



$$p(x, y, \theta) = \prod_{t=1}^T p(y_t | y_{t-1}, \theta) p(x_t | y_t, \theta_t)$$

A B

No.

Date.

11.1.3 无向图模型 (马尔科夫随机场)

11.1.4 无向图模型的概率分解

11.1.5 常见的无向图模型.

对数线性模型 (最大熵模型)

条件随机场 CRF

11.1.5.1 对数线性模型.

$f_c(x_c)$ 特征向量.

θ_c 权重向量.

势能函数


$$\phi_c(x_c | \theta_c) = \exp(\theta_c^T f_c(x_c))$$

对数线性模型

$$\log p(x | \theta) = \sum \theta^T f_c(x_c) - \log Z(\theta)$$

$$p(y | x, \theta) = \frac{1}{Z(x, \theta)} \exp(\theta^T f_c(x, y))$$

11.1.5.2 CRF



$$p(y | x) = \frac{1}{Z(x, \theta)} \exp(\sum \theta_c^T f_c(x, y_c))$$

11.2 推断

11.3 近似推断

11.3.1 采样法 (蒙特卡罗方法)

计算函数 $f(x)$ 的期望, (已知 $p(x)$)

$$E(f(x)) = \int_x f(x) p(x) dx$$

随机采样

11.3.2 拒绝采样

引入一个容易采样的分布 $q(x)$. — 提议分布

构建一个提议分布 $q(x)$ 和常数 k , 使得 $kg(x)$ 可以覆盖目标函数 $\hat{p}(x)$

$$\text{即 } kg(x) \geq \hat{p}(x)$$

对于每次抽取的样本 x , 计算接受概率 $\alpha(x)$, 并以 $\alpha(x)$ 来接受样本 x .

$$\alpha(x) = \frac{\hat{p}(x)}{kg(x)}$$

11.3.3 重要性采样

$$\begin{aligned}
 E_p[f(x)] &= \int_x f(x) p(x) dx \\
 &= \int_x f(x) \frac{p(x)}{g(x)} g(x) dx \\
 &= \int_x f(x) w(x) g(x) dx \\
 &= E_g[f(x) w(x)].
 \end{aligned}$$

$w(x)$ 重要性权重.

将分布 $p(x)$ 在 $f(x)$ 的期望变为分布 $g(x)$ 在 $f(x) w(x)$ 的期望.

11.3.4 MCMC

高维空间采样

- MH 算法

- Metropolis 算法

- 吉布斯采样

11.4 学习

11.4.1 不含隐变量的参数估计

有向图 极大似然估计

无向图 采样 / 坐标上升法

11.4.2 含隐变量的参数估计

11.4.2.1 EM 算法

一个样本的极大似然函数

$$p(x|\theta) = \sum_z p(x, z|\theta)$$

带隐变量的贝叶斯网络

